گزارش تمرین شماره دو BIG DATA

تاریخ تحویل : ۹۸/۸/۱۸ نمره : ۱/۵

---

۱. پایگاه داده KDDCUP99 که توضیحات آن در فایل پیوست آورده شده است داراي دو فایل آموزش kddcup.data.gz و تست corrected.gz میباشد. میخواهیم با استفاده از RANDOM FOREST در SPARK دقت کلاسبندي و زمان اجرا بر روي ۴ هسته را براي پنج کلاس اصلي DOSو R2L و U2R و probing و NORMAL در حالات زیر بدست آوریم.

ابتدا داده ها را با فرمت txt دخیره کرده و آنها را پارس میکنیم سپس با بکارگیری pipeline ، مسیری برای آماده سازی اطلاعات و مدل پیش میگیریم ، که در ابتدا ویژگی های کتگوریکال را به عدد هایی که متناسب با تعداد آنها فضای کمتری در را ذخیره میکند ، تبدیل میکنیم و سایر ویژگی های عددی را به صورت بردار در آورده و با اضافه کردن یک بخش دیگر به پایپ لاین ویژگی ها را در یک بردار به کمک assembler آماده کرده و سپس به مدل میدهیم ، سپس اطلاعات به پایپ لاین فیت میکنیم

برای بررسی روند اصلی ، دادگان اموزش را به دو دسته train و validation تقسیم میکنیم. تا از میزان یادگیری اطلاعات مطلع شویم. برای نمونه بر روی یک جنگل با ۱۰ درخت ، ۷۰ شاخه ای و عمق ۱۰ نتایج زیر حاصل شد :

```
accuracy is on validation is 0.9995019747517527

accuracy is on test is 0.5277867980156191
```

که به این معنا است که درخت داده های آموزش را به طور کامل فراگرفته و برای داده های تست نمیتواند عملکرد مناسبی داشته باشد. این حالت به این معنا است که دیتایی که برای تست مشخص شده ، با اطاعاتی که برای آموزش در نظر گرفته شده ، متفاوت است و از به مدل خوبی استفاده نشده یا اطلاعات برای مدل استفاده شده مناسب نیست ، با حال با تغییر در پارامتر های مدل به بررسی بیشتر مدل پیشنهادی میپردازیم:

الف: دو نمودار دقت و زمان اجرا را براي تعداد درخت ۱۰-۲۰-۳۰-۴۰-۵۰ و حداکثر عمق درخت ۱۰ رسم کنید.

میزان دقت برای validation

10	0.9995734127996571
20	0.999789768030453
30	0.9996407686733955
40	0.9998122199883658
50	0.9997040423729678

میزان دقت برای test

10	0.5278864671783017
20	0.5275971050930942
30	0.527664622912976
40	0.5276196110330548
50	0.5276324715701751

زمان اجرا

Elapsed time: 251781098600ns
Elapsed time: 283303074100ns
Elapsed time: 355545961000ns
Elapsed time: 496468348000ns
Elapsed time: 769343439400ns

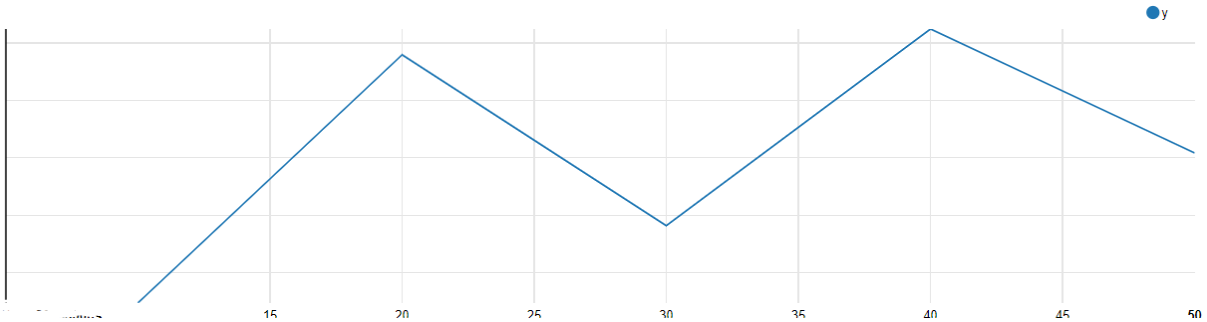

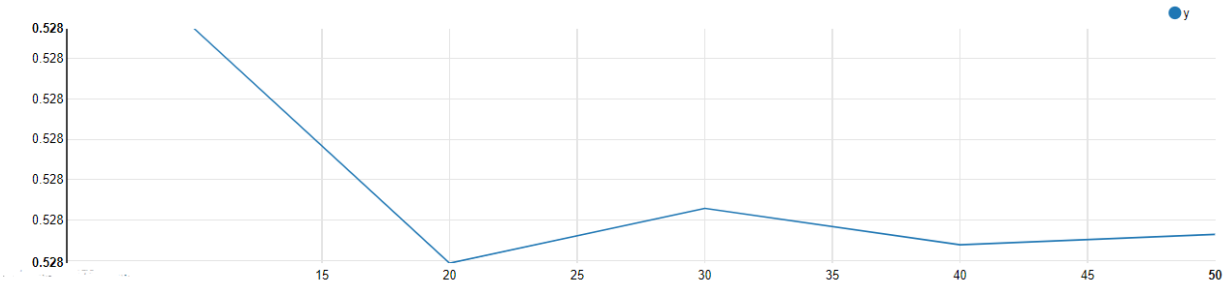

ب:بهترين جواب بخش الف را با حداكثر عمق درخت ۲۰ و با معيارهاي GINI يا ENTROPY تكرار كنيد

```
gini in validation is 0.9999142743425148
gini in test is 0.5294715283783827

entropy in validation is 0.9999224386908467
entropy in test is 0.5277675072099386
```

ج : مقادير متريک هاي زير را براي بهترين جواب ارايه دهيد

```
f1 is0.5302292139352637
weightedPrecision is0.5329607544319456
weightedRecall is0.5294715283783827
accuracy is0.5294715283783827
```

خروجي گزارش شامل كد، نتايج، نمودار و تحليل ان مي باشد.

کد:

```
import org.apache.spark._
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext._
import org.apache.spark.rdd.RDD._

import org.apache.spark.ml.linalg.{Vector, Vectors}

def time[R](block: => R): R = {
    val t0 = System.nanoTime()
    val result = block    // call-by-name
    val t1 = System.nanoTime()
    println("Elapsed time: " + (t1 - t0) + "ns")
    result
}
def parser(line:String)={
    val num =line.split(",")
    val label=num(41)
    val x0=num(0).toDouble
    val x1=num(1)
    val x2=num(2)
    val x3=num(3)
    val x4=num.dropRight(1).drop(4).map(t=>t.toDouble)
    (label,x0,x1,x2,x3 ,Vectors.dense(x4))
}



val Data = sc.textFile("C:/BigData/HW2/kddcup.txt").map(parser).toDF("label","f0","f1","f2","f3","f4")
val Array(trainData,valData) = Data.randomSplit(Array(0.9, 0.1), seed = 123)
val test = sc.textFile("C:/BigData/HW2/kddcup-test.txt").map(parser).toDF("label","f0","f1","f2","f3","f4")
//make string categorical thing to vector
import org.apache.spark.ml.feature.{IndexToString, StringIndexer, VectorIndexer}

//prepare label
val labelIndexer = new StringIndexer()
  .setInputCol("label")
  .setOutputCol("indexedLabel")

//prepare f1
val F1Indexer = new StringIndexer()
  .setInputCol("f1")
```

```
   .setOutputCol("Ft1")


//prepare f2
 val F2Indexer = new StringIndexer()
  .setInputCol("f2")
  .setOutputCol("Ft2")


//prepare f3
  val F3Indexer = new StringIndexer()
  .setInputCol("f3")
  .setOutputCol("Ft3")



import org.apache.spark.ml.feature.VectorAssembler

val assembler = new VectorAssembler()
   .setInputCols(Array("f0","Ft1","Ft2","Ft3","f4"))
   .setOutputCol("Features")


import org.apache.spark.ml.classification.{RandomForestClassificationModel, RandomForestClassifier}
val rf = new RandomForestClassifier()
  .setLabelCol("indexedLabel")
  .setFeaturesCol("Features")
  .setImpurity("entropy")
  .setMaxDepth(10)
  .setNumTrees(10)
  .setFeatureSubsetStrategy("auto")
  .setSeed(123)
  .setMaxBins(70)



import org.apache.spark.ml.Pipeline

val testData = new Pipeline().setStages(Array(labelIndexer, F1Indexer, F2Indexer, F3Indexer))
                        .fit(test).transform(test).select("f0","Ft1","Ft2","Ft3","f4","indexedLabel")

val pipeline = new Pipeline()
```

```
  .setStages(Array(labelIndexer, F1Indexer, F2Indexer, F3Indexer, assembler ,rf ))
val model = pipeline.fit(trainData)
val predictionsV=model.transform(valData)
val predictionsT=model.transform(testData)

import org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator

val evaluator = new MulticlassClassificationEvaluator()
       .setLabelCol("indexedLabel")
       .setPredictionCol("prediction")
       .setMetricName("accuracy")

 println("accuracy is on validation is "+ evaluator.evaluate(predictionsV) )



 println("accuracy is on test is "+ evaluator.evaluate(predictionsT) )
//part a
//Tree-10,20,30,40,50 -time -accuracy
import org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator

val seed = 100
val evaluator = new MulticlassClassificationEvaluator()
     .setLabelCol("indexedLabel")
     .setPredictionCol("prediction")
     .setMetricName("accuracy")

println("%table\nx \ty")
(10 to 50 by 10).map(numtree =>(
            numtree,time{evaluator.evaluate{new     Pipeline().setStages(Array(labelIndexer,     F1Indexer,     F2Indexer,
F3Indexer, assembler ,
                                        new RandomForestClassifier()
                                                .setLabelCol("indexedLabel")
                                                .setFeaturesCol("Features")
                                                .setImpurity("entropy")
                                                .setMaxDepth(10)
                                                .setNumTrees(numtree)
                                                .setFeatureSubsetStrategy("auto")
                                                .setSeed(123)
                                                .setMaxBins(100)
                                        ))
                                      .fit(trainData)
                                      .transform(valData)
```

```
                }
            }
        )
    ).foreach{case (x,y) => println(x + "\t" + y)}
//part a
//Tree-10,20,30,40,50 -time -accuracy in testdata

import org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator

val seed = 100
val evaluator = new MulticlassClassificationEvaluator()
  .setLabelCol("indexedLabel")
  .setPredictionCol("prediction")
  .setMetricName("accuracy")

println("%table\nx \ty")
(10 to 50 by 10).map(numtree =>(
        numtree,time{evaluator.evaluate{new Pipeline().setStages(Array(labelIndexer, F1Indexer, F2Indexer,
F3Indexer, assembler ,
                                    new RandomForestClassifier()
                                        .setLabelCol("indexedLabel")
                                        .setFeaturesCol("Features")
                                        .setImpurity("entropy")
                                        .setMaxDepth(10)
                                        .setNumTrees(numtree)
                                        .setFeatureSubsetStrategy("auto")
                                        .setSeed(123)
                                        .setMaxBins(100)
                                    ))
                                .fit(trainData)
                                .transform(testData)


                }
            }
        )
    ).foreach{case (x,y) => println(x + "\t" + y)}
//gini in validation
println(
    evaluator.evaluate{new Pipeline().setStages(Array(labelIndexer, F1Indexer, F2Indexer, F3Indexer, assembler ,
```

```
                                        new RandomForestClassifier()
                                                .setLabelCol("indexedLabel")
                                                .setFeaturesCol("Features")
                                                .setImpurity("gini")
                                                .setMaxDepth(20)
                                                .setNumTrees(10)
                                                .setFeatureSubsetStrategy("auto")
                                                .setSeed(123)
                                                .setMaxBins(100)
                                        ))
                                    .fit(trainData)
                                    .transform(valData)}

    )
//gini in test
println(
    evaluator.evaluate{new Pipeline().setStages(Array(labelIndexer, F1Indexer, F2Indexer, F3Indexer, assembler ,
                                        new RandomForestClassifier()
                                                .setLabelCol("indexedLabel")
                                                .setFeaturesCol("Features")
                                                .setImpurity("gini")
                                                .setMaxDepth(20)
                                                .setNumTrees(10)
                                                .setFeatureSubsetStrategy("auto")
                                                .setSeed(123)
                                                .setMaxBins(100)
                                        ))
                                    .fit(trainData)
                                    .transform(testData)}

    )
//entropy in val
println(
    evaluator.evaluate{new Pipeline().setStages(Array(labelIndexer, F1Indexer, F2Indexer, F3Indexer, assembler ,
                                        new RandomForestClassifier()
                                                .setLabelCol("indexedLabel")
                                                .setFeaturesCol("Features")
                                                .setImpurity("entropy")
                                                .setMaxDepth(20)
                                                .setNumTrees(10)
                                                .setFeatureSubsetStrategy("auto")
                                                .setSeed(123)
```

```
                                        .setMaxBins(100)
                                    ))
                                .fit(trainData)
                                .transform(valData)}

        )
//entropy in test
println(
        evaluator.evaluate{new Pipeline().setStages(Array(labelIndexer, F1Indexer, F2Indexer, F3Indexer, assembler ,
                                    new RandomForestClassifier()
                                        .setLabelCol("indexedLabel")
                                        .setFeaturesCol("Features")
                                        .setImpurity("entropy")
                                        .setMaxDepth(20)
                                        .setNumTrees(10)
                                        .setFeatureSubsetStrategy("auto")
                                        .setSeed(123)
                                        .setMaxBins(100)
                                    ))
                                .fit(trainData)
                                .transform(testData)}

        )
val Model=new Pipeline().setStages(Array(labelIndexer, F1Indexer, F2Indexer, F3Indexer, assembler ,
                                    new RandomForestClassifier()
                                        .setLabelCol("indexedLabel")
                                        .setFeaturesCol("Features")
                                        .setImpurity("gini")
                                        .setMaxDepth(20)
                                        .setNumTrees(10)
                                        .setFeatureSubsetStrategy("auto")
                                        .setSeed(123)
                                        .setMaxBins(100)
                                    ) )
                                .fit(trainData)
                                .transform(testData)
val p1 =evaluator.setMetricName("f1").evaluate(Model)
val p2 =evaluator.setMetricName("weightedPrecision").evaluate(Model)
val p3 =evaluator.setMetricName("weightedRecall").evaluate(Model)
val p4 =evaluator.setMetricName("accuracy").evaluate(Model)

println("f1 is"+p1+"weightedPrecision is"+p2+"weightedRecall is"+p3+"accuracy is"+p4)
```

۲. پایگاه داده MNIST که توضیحات آن در پیوست آورده شده براي آموزش و تست یک درخت تصمیم گیري در SPARK استفاده مي شود

برای استفاده از اطلاعات ابتدا خارج از zeppelin داده ها به شکل csv (جدا شده با کاما) تبدیل شد ، سپس الگوریتم روی آن اجرا شد.

الف : نمودار دقت را با تغییر عمق درخت از k=3 to8 رسم نمایید.

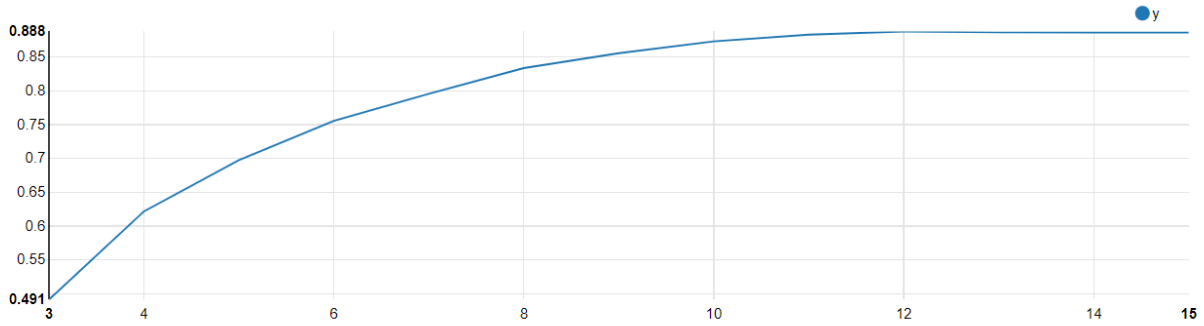

میزان بهینه ماکزیمم عمق درخت ۱۱ است.

ب: با در نظر گرفتن عمق بهینه درخت پارامتر MaxBins را بین مقادیر ۴ و ۸ و ۱۶ و ۳۲ تغییر دهید. نمودار دقت خروجي را بر حسب این پارامتر رسم نمایید و تغییرات موجود در دقت نتایج را توضیح دهید.

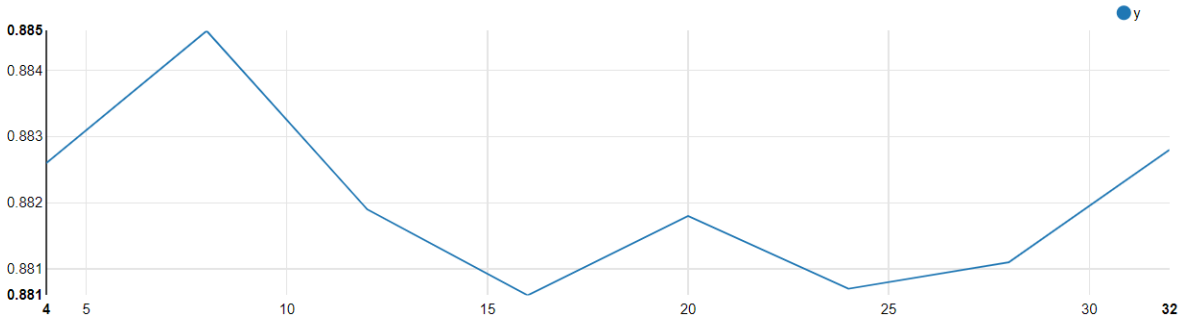

دامنه تغییرات به طور کلی در حدود همان ۸۸ درصد دقت است ولی برای توجیح جزئیات آن MaxBins تعداد شاخه های خروجی هر نود است ، که بر اساس داکیومنت اسپارک باید بیشتر یا مساوی تعداد نوع ها در بردار ویژگی باشد ، از آن جایی که بردار ویژگی ما تصویر است و عمل رگرسیون انجام نمی دهیم پس عدد هر پیکسل به واقع یک نوع از آن دسته محسوب میشود ولی با بررسی این عدد دقت همچنان ۸۸ درصد است، چرا که هر چند دامنه ها بیانگر دسته های مختلف هستند ولی دامنه تغییرات آن ها ثابت است (تعدادی در حدود ۲۵۰ تعدادی در حدود ۱۰۰ تعدادی در حدود ۰) پس بجای انتخاب عدد ۲۵۵ میتوان از عددهای کوچکتر استفاده نمود ، با توجه به انتخاب میزان بهینه عمق درخت ۱۱ ویژگی در لایه های پایین تر به طور کامل از یکدیگر جدا شده و نتیجه را در حدود ۸۸ درصد نگه میدارند با این حال برای توجیه نوسانات ، میتوان گفت که ما ۱۰ دسته برای خروجی داریم و ویژگی ها را باید در ۱۰ دسته تقسیم کنیم که در نواحی مضارب ۱۰ نمودار دقت ، بهبود میابد

گزارش شامل کد و نتایج و نمودارهاي هر مرحله و تحلیل جواب ها مي باشد.

کد:

```
import org.apache.spark._
import org.apache.spark.SparkConf
import org.apache.spark.SparkContext._
import org.apache.spark.rdd.RDD._

import org.apache.spark.ml.linalg.{Vector, Vectors}
//read

def parser(line:String)={
   val num =line.split(",")
   val label=num(0).toInt
   val feature=num.drop(1).map(t=>t.toDouble)
   (label ,Vectors.dense(feature) )
}

 val training = sc.textFile("C:/BigData/HW2/mnist_train.txt").map(parser).toDF("label", "features")
 val testing = sc.textFile("C:/BigData/HW2/mnist_test.txt").map(parser).toDF("label", "features")
import org.apache.spark.ml.classification.{DecisionTreeClassifier, DecisionTreeClassificationModel}

val dtc = new DecisionTreeClassifier()
              .setImpurity("entropy")
              .setMaxBins(255)
              .setMaxDepth(11)
              .setSeed(123)
              .fit(training)
```

```
val perdiction = dtc.transform(testing)

perdiction.select("label","prediction").show(10)


import org.apache.spark.ml.evaluation.MulticlassClassificationEvaluator

val evaluator = new MulticlassClassificationEvaluator()

                        .setLabelCol("label")

                        .setPredictionCol("prediction")

                        .setMetricName("accuracy")

val accuracy = evaluator.evaluate(perdiction)


println ("accuracy is :"+ accuracy*100 +" percent \n" )

//2-1

//MaxDepth => 3 to 10


val evaluator = new MulticlassClassificationEvaluator()

                        .setLabelCol("label")

                        .setPredictionCol("prediction")

                        .setMetricName("accuracy")


println("%table\nx \ty")

(3 to 15).map(MaxDepth=>(MaxDepth,evaluator.evaluate{

                                        new DecisionTreeClassifier()

                                          .setImpurity("entropy")

                                          .setMaxBins(32)

                                          .setMaxDepth(MaxDepth)

                                          .setSeed(123)

                                          .fit(training)

                                          .transform(testing)
```

```
                                        }
                    )
            ).foreach{case (x,y) => println(x + "\t" + y)}

//2-1
//MaxBins => 3 to 10

val evaluator = new MulticlassClassificationEvaluator()
                        .setLabelCol("label")
                        .setPredictionCol("prediction")
                        .setMetricName("accuracy")

println("%table\nx \ty")
(4 to 32 by 4).map(MaxBins=>(MaxBins,evaluator.evaluate{
                                        new DecisionTreeClassifier()
                                          .setImpurity("entropy")
                                          .setMaxBins(MaxBins)
                                          .setMaxDepth(11)
                                          .setSeed(123)
                                          .fit(training)
                                          .transform(testing)
                                        }
                    )
            ).foreach{case (x,y) => println(x + "\t" + y)}
```